1. 所用AI工具名称和版本

我队所用AI工具及版本为DeepSeek-V3.1。

2. 具体使用目的和环节

我队使用AI工具是为了辅助我们理解一些专有名词和代码编写,并帮助我们理清建模思路 ,有时用来小范围处理数据。 在模型选择、数据处理和代码编写过程中使用了AI工具。

3. 关键交互记录(重要提示词与回复)

提示词1: 简要介绍一下微平均AUC, 召回率和F1-Score的作用回复1: 好的, 这是对这三个指标在您模型中作用的简要介绍:

- - -

1. 微平均AUC (Micro-Averaged AUC)

作用:提供模型整体分类性能的"终极评价",它综合考量了所有类别(正常和各种异常)的预测情况,给出一个**全局的、综合的**区分能力分数(0.969意味着模型整体区分能力极佳)。

2. 召回率 (Recall)

作用: 衡量模型的"查全率"或"防漏诊能力", 它回答"在所有真实异常样本中, 模型成功找出了多少?"(0.904意味着模型能成功捕捉到90.4%的真实异常病例, 漏诊率控制得较好)。

3. F1-Score (F1分数)

作用:精准率和召回率的"调和平均",是模型实用性的"平衡指标",它同时考虑了误报(假阳性)和漏报(假阴性),用于评估模型在精确性和全面性之间的**综合平衡水平**(0.858是一个良好的分数,表明模型在两方面取得了不错的平衡)。

提示词2:读取这个表中的BMI值和预测时间,以numpy数组的形式呈现回复2:以下是提取自Excel文件"个体预测结果"工作表中BMI列和预测达到时间列的NumPy数组:

```python import numpy as np

# BMI 数据(E列)

bmi\_values = np.array([

33.3318319, 30.7421875, 28.64124339, 30.84444444, 35.8836345, 33.87406376, 29.13631634, 33.33333333, 33.33333333, 36.25047023, 30.38501561, 35.75595619, 35.05563176, 30.88888889, 30.44383913, 28.28282828, 28.13365651, 28.3203125, 35.68444444, 28.67766307, 30.0432623, 33.28402367, 29.75206612, 28.04037814, 29.13631634, 32.04614645, 35.05886427, 30.38501561, 30.48315806, 32.56188509, 36.88509165, 30.84627667, 34.72222222, 29.44636678, 28.40787731, 30.11099051, 29.75206612, 31.68506006, 35.69303986, 37.11354644, 30.11937557, 30.12048193, 29.74419988, 28.3446712, 28.90625, 33.87406376, 32.69054178, 34.92767916, 38.56749311, 39.15984336, 28.90625, 36.13233468, 32.05128205, 34.2893767, 31.22945431, 31.7329413, 38.94681326, 36.28973726, 31.640625, 32.04614645, 31.63371488, 32.04614645, 30.42719786, 33.7890625, 30.46875, 34.72088268, 31.64428577, 33.71488033, 27.91551883, 35.546875, 34.06360931, 29.17488494,

```
31.8877551, 30.44383913, 32.8125, 29.16933268, 32.29786616, 28.14760026,
 32.36854981, 30.48315806, 30.48665738, 32.52244898, 29.12414966, 30.66129192,
 30.4833793, 29.75206612, 27.20249836, 36.92307692, 30.0432623, 41.1328125,
 29.76086271, 36.64044563, 37.63784862, 30.11621315, 28.98114344, 33.40920489,
 31.99217133, 32.83941526, 28.79295419, 29.76086272, 40.1384083, 32.24206349,
 30.11940192, 34.0490306, 30.86303587, 33.46222487, 35.68535165, 30.44383913,
 37.29068808, 30.42719786, 29.89969136, 26.61934339, 31.25, 29.13631634,
 35.3798127, 31.25, 29.06574394, 30.11940191, 30.859375, 28.26602431, 32.8125,
 29.38475666, 29.61580592, 28.83379247, 30.46875, 29.49494949, 29.296875,
 39.30211203, 30.47052154, 29.41176471, 30.078125, 31.28831929, 28.3446712
 31.7535201, 29.13631634, 29.68943569, 35.41912633, 34.51676529, 29.64268547, 30.47052154, 28.98114344, 34.15977961, 37.8328742, 38.75432526, 36.36363636,
 31.22130395, 32.0, 33.203125, 33.0449827, 28.07108864, 30.3758766544418,
 31.3209292888397, 29.9717084841169, 32.5719340208979, 33.209911121107, 33.1012728287967, 29.4736538333721, 31.7136830091578, 29.8781281581312,
 34.33941771,
32.0248107555561.
 30.3208818878574,
 33.1447392272428,
30.4923029789054.
 33.4284464919266,
 30.7297875520508,
30.99686586,
 29.3337456517114,
34.1412917452927,
 32.4255843278135, 30.6293529774186, 27.8813428504966, 35.5478156953067,
 38.5381074441282, 33.2866648308078, 33.5557029891529, 33.8632982242097,
 30.1851951136848, 31.0963695756299, 28.1934816309429, 30.5560048250251,
 33.1123119118124, 31.3448155261195, 31.6343053186995, 31.6847260842043,
 28.1712732058412, 33.7202666866985, 31.4499376707056, 30.6461845488005,
 31.7615661558367, 34.5009831046413, 30.5986033786627, 30.1460126719457,
 30.282667953009, 29.4856532028141, 32.7160219738708, 29.8911616220665,
 32.3448873999274, 34.5703607329656, 29.0105368357815, 30.2458011293154,
 33.8620938519375,\ 33.7157164956164,\ 35.568089454265,\ 31.7837952858894,
 28.6124502205125, 30.1808820146395, 32.8532626271359, 35.6122889742016,
 32.017138236274, 34.2127437287273, 33.2175315995461, 29.7254508618786,
 31.6317360439571, 34.7516889098776, 33.517889736661, 32.8746489913239,
 32.5536868976708, 30.7633136737466, 29.090374615573, 34.4843990684449,
 29.1257872485132, 30.0283256679736, 33.0200653600827, 29.0378761457738, 30.7588525202617, 29.4190260663914, 33.3046399184317, 32.311708576773, 32.5941312641211, 32.5579873449767, 32.9258922118661, 33.0500666835481, 28.0649314858714, 31.6072618505741, 32.1364343541481, 33.341955021822, 29.7475745109286, 30.8048703888565, 30.7755173191146, 33.7864936354758,
 34.215671325648, 33.885075883237, 29.3466867640343, 32.4710620375276,
 34.0598770272484, 32.1350948388576, 30.7031331865731
1)
预测达到时间数据(F列)
predicted_times = np.array([
 104.7657650889461, 98.6361085039231, 93.92768896770228, 98.87120619040148.
 111.1783529993479, 106.0966824536452, 95.0165453915245, 104.7694272264577,
 104.7694272264577, 112.1319179331059, 97.81931668414178, 110.8483676687522,
 109.0557175386482, 98.97356250782477, 97.95336940228962, 93.14719086984776,
 92.82426333516005, 93.22851329689031, 110.6639732311948, 94.00736294021006,
 97.0441173803967, 104.6492229551822, 96.38844606996028, 92.62290316787374,
 95.0165453915245, 101.6763715436442, 109.0639249695997, 97.81931668414178,
 98.0430755977554, 102.9045519696209, 113.8009273291487, 98.87542375423288,
 108.2124903378286, 95.70488465753765, 93.41876287367735, 97.1972556836042,
 96.38844606996028, 100.825214739916, 110.6861204601267, 114.4078091026523,
 97.21623170439666, 97.21873575684442, 96.37079565239087, 93.28139782017097, 94.50897960808693, 106.0966824536452, 103.2132402310942, 108.7313380080496, 118.3467345781532, 119.9901049508017, 94.50897960808693, 111.8239430139409, 101.6885289174925, 107.1274983744358, 99.76141546308088, 100.9376698528392,
 119.3964795537607, 112.2344733041713, 100.7209655023218, 101.6763715436442,
 100.7047633348911, 101.6763715436442, 97.9154270458229, 105.8869333560658, 98.01019405562938, 108.2091156866719, 100.7295499707974, 105.7042203278441,
 92.3540526753473, 110.3101099318437, 106.5659025023523, 95.10190072928374,
 101.3021286253484, 97.95336940228962, 103.5067116177924, 95.0896084193312,
 102.2739748763501, 92.85440131732864, 102.4424144239946, 98.0430755977554,
```

```
98.05106328138713, 102.8101172089319, 94.98963547224042, 98.45051857497805,
 98.04358058949492, 96.38844606996028, 90.83364201295167, 113.9016102123067,
 97.0441173803967, 125.6301251883535, 96.40818785322698, 113.1546032519116,
 115.8128636132929, 97.20907447523227, 94.67390901795865, 104.9546523023513,
 101.5486855098076, 103.5715908564742, 94.26002689092827, 96.40818787567179,
 122.7550984149682, 102.1411924444493, 97.21629134226544, 106.5297393530575,
 98.91400968211995, 105.0842842060049, 110.6663105677601, 97.95336940228962,
 114.8806061349353, 97.9154270458229, 96.72029062460594, 89.60877614496424,
 99.8091452817016, 95.0165453915245, 109.8819046132697, 99.8091452817016,
 94.860561418253, 97.2162913196324, 98.9055797090644, 93.11075750435933,
 103.5067116177924, 95.567708917877, 96.08315935176064, 94.34968798871324
 98.01019405562938, 95.81319353358113, 95.3723794337604, 120.3881907724046,
 98.01423640408095, 95.62781847483207, 97.12291426913076, 99.89822608071688,
 93.28139782017097, 100.9860402818254, 95.0165453915245, 96.24800427639045,
 109.9825214514454, 107.6961185465586, 96.14330548919412, 98.01423640408095,
 94.67390901795865, 106.8047650659206, 116.3398959541721, 118.8626224604215,
 112.42773315752, 99.74248763551412, 101.567195425894, 104.452311465949,
 104.0684544742472, 92.68914969554699, 97.79850642113324, 99.97409711537473,
 96.88259120544191, 102.9286292720437, 104.4688149845661, 104.2049248940922,
 95.76570253770356, 100.8924242644499, 96.67174787030957, 101.6258796631732,
 107.2523754190777, 97.67337160122067, 104.3104277559046, 98.0639515164466,
 99.22267694723512, 105.0016788153465, 98.60763796515158, 95.45428104037538,
 106.7588043799252, 102.5785302190697, 98.37734072147171, 92.2806001476872,
 110.3125257911006, 118.2657978122822, 104.6556579289914, 105.3132248876768,
 106.0700944573608, 97.36531501111456, 99.45279778538952, 92.95363827231287,
 98.20949275497519, 104.2317091528446, 100.0297078423617, 100.7061476354441,
 100.8244307959174, 92.90559036619943, 105.7174764728844, 100.2748157578375,
 98.4158980925121, 101.004958822881, 107.6565554763012, 98.30693926102248,
 97.27653804881218, 97.58651409730732, 95.79245918330295, 103.2744850759804,
 96.70108569411578, 102.3859958969492, 107.8305811360585, 94.73871741133543,
 97.50279168324901, 106.0671203941508, 105.7062780722933, 110.3646049765448,
 101.057244185491, 93.86474702597103, 97.35553871202569, 103.6049857789225,
 110.4782298495871, 101.607728431561, 106.9365430143361, 104.4873507280933,
 96.32873928362369, 100.7001240354925, 108.2867512532182, 105.2205550551591, \\103.6565832378897, 102.8849132204424, 98.68463357298558, 94.91497272023734, \\
 107.614997971855, 94.9932570003661, 97.01037707827658, 104.008101677576,
 94.79903664960005, 98.67438468551661, 95.64398591603376, 104.6994632817935,
 102.3069396134485, 102.9818339759268, 102.8952144637781, 103.7803189228485,
 104.0807727954034, 92.67586411991901, 100.6427629645986, 101.8903197813181,
 104.7904588709007, 96.37836731697001, 98.7801555773085, 98.71267521152572,
 105.8806008857221, 106.9438317936597, 106.1238863504313, 95.48304409600554,
 102.6871946889408, 106.5566432372992, 101.8871423482704, 98.5464668015696
])
```

这两个数组分别包含了所有样本的BMI值和对应的预测达到时间(单位:天),可用于后 续分析或可视化。

```
提示词3:Traceback (most recent call last):
 File "C:\Users\qians\Desktop\数模\问题2-风险.py", line 62, in <module>
 df['bmi_group'] = df['bmi'].apply(assign_bmi_group)
 ~`~^^^^
```

"C:\Users\qians\Desktop\数模\.venv\Lib\site-packages\pandas\core\frame.py", line 4107, in \_\_getitem\_

indexer = self.columns.get loc(key)

File "C:\Users\qians\Desktop\数模\.venv\Lib\site-packages\pandas\core\indexes\range.py", line 417, in get\_loc

raise KeyError(key)

报错是为什么 KeyError: 'bmi'

回复3: 这个错误是因为你试图对一个列表(list)对象使用 `split()` 方法, 但列表对象没有 这个方法。`split()` 是字符串(string)对象的方法。

错误发生在这一行:

```
"python
lines = file_content.split('\n')
这意味着 `file_content` 变量是一个列表而不是字符串。可能的原因和解决方法:
1. **文件读取方式问题**:
 - 如果你使用了 `readlines()` 方法读取文件,它会返回一个包含所有行的列表,而不是一
个字符串
 - 示例错误代码:
   ```python
  with open('file.txt', 'r') as f:
     file_content = f.readlines() #返回列表
   lines = file_content.split('\n') # 错误: 对列表使用split()
2. **解决方案**:
- 如果你想要逐行处理,可以直接使用 `readlines()` 返回的列表:
    `python
  with open('file.txt', 'r') as f:
  lines = f.readlines() # 直接使用这个列表
  - 或者使用 `read()` 读取为字符串再分割:
   "python
  with open('file.txt', 'r') as f:
     file_content = f.read() # 读取为字符串
     lines = file_content.split('\n') # 正确: 对字符串使用split()
3. **检查 `file_content` 的类型**:
  - 你可以在代码中添加 `print(type(file_content))` 来确认变量的类型
  - 如果是列表,就不需要再使用 `split()` 方法
请检查你的文件读取代码,确保正确处理了文件内容的数据类型。
提示词4: import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
# --- 1. 数据准备与合并 ---
# 您的原始数据
# 为了代码简洁,这里仅展示部分数据,但代码会使用完整数组
bmi_data = np.array([
33.331832, 30.742188, 28.641243, 30.844444, 35.883635, 33.874064, 29.136316, 33.333333,
33.333333, 36.25047,
30.385016, 35.755956, 35.055632, 30.888889, 30.443839, 28.282828, 28.133657, 28.320313,
35.684444, 28.677663,
30.043262, 33.284024, 29.752066, 28.040378, 29.136316, 32.046147, 35.058864, 30.385016,
30.483158, 32.561885,
36.885092, 30.846277, 34.722222, 29.446367, 28.407877, 30.110991, 29.752066, 31.68506,
35.69304, 37.113546,
30.119376, 30.120482, 29.7442, 28.344671, 28.90625, 33.874064, 32.690542, 34.927679, 38.567493, 39.159843, 28.90625, 36.132335, 32.051282, 34.289377, 31.229454, 31.732941, 38.946813, 36.289737,
31.640625, 32.046147,
31.633715, 32.046147, 30.427198, 33.789063, 30.46875, 34.720883, 31.644286, 33.71488, 27.915519, 35.546875,
34.063609, 29.174885, 31.887755, 30.443839, 32.8125, 29.169333, 32.297866, 28.1476,
32.36855, 30.483158,
30.486657, 32.522449, 29.12415, 30.661292, 30.483379, 29.752066, 27.202498, 36.923077,
30.043262, 41.132813,
```

29.760863, 36.640446, 37.637849, 30.116213, 28.981143, 33.409205, 31.992171, 32.839415,

```
28.792954, 29.760863,
40.138408, 32.242064, 30.119402, 34.049031, 30.863036, 33.462225, 35.685352, 30.443839,
37.290688, 30.427198,
29.899691, 26.619343, 31.25, 29.136316, 35.379813, 31.25, 29.065744, 30.119402,
30.859375, 28.266024,
32.8125, 29.384757, 29.615806, 28.833793, 30.46875, 29.49495, 29.296875, 39.302112,
30.470522, 29.411765,
  30.078125, 31.288319, 28.344671, 31.75352, 29.136316,
93.2437362, 110.400254, 116.668369, 102.650094, 103.183044, 103.963022, 95.0016603,
95.415381, 92.6156291,
97.0200954, 106.028275, 103.075164, 99.6682325, 103.251199, 92.1627171, 105.522922,
98.2973017, 95.0638845,
101.23238, 105.420952, 94.3469718, 97.9953125, 93.867685, 93.301505, 101.013913,
98.876758, 102.972457,
110.120956, 93.9075711, 95.8539553, 105.023262, 103.332831, 112.496414, 97.0934702.
96.3381935, 95.2139932,
  101.561435, 108.071684, 98.9923231, 104.289514, 101.090093, 92.483819, 99.3598283,
106.940275, 107.123329
102.449745, 101.603933, 95.799683, 88.1709798, 106.453144, 91.5031118, 93.7045037,
106.975997, 92.0742743,
94.8728431, 93.8317202, 106.904949, 103.550073, 101.429151, 100.366948, 103.090875,
105.74492, 91.5759535,
99.9182265, 99.9311178, 102.6302, 96.6050429, 99.898312, 98.2269621, 103.833722,
104.155406, 104.956193,
  92.0702004, 102.010799, 104.745771, 99.4175256, 94.9556487
])
predicted times = np.array([
100.668648, 98.3450393, 93.6862885, 95.9107209, 111.453665, 107.776385, 91.3624041,
105.196725, 101.293993,
113.661462, 94.369971, 112.010178, 107.186998, 95.2416782, 98.6940104, 95.3363747,
88.5386008, 91.1535402,
109.30739, 93.4905442, 96.7259696, 101.486614, 97.7676682, 90.2793576, 93.6062648,
101.029713, 106.279369,
95.3811131, 98.412584, 102.124561, 114.636413, 100.932574, 108.738427, 96.621701, 88.4480187, 100.894938,
96.1065093, 98.1898903, 108.389175, 112.353868, 97.8008012, 97.8282944, 96.0304249,
95.7422319, 92.7911029,
104.390534, 104.547343, 106.724604, 119.253375, 119.582628, 93.5647985, 111.443239,
99.4098514, 104.877116,
97.282596, 101.133205, 119.930768, 110.60438, 101.701524, 100.259151, 97.5789036,
99.9057308, 95.5809152,
105.451475, 96.6019781, 106.924252, 98.2832034, 101.854997, 91.6176793, 108.870651,
108.498394, 91.51288,
101.681329, 97.3665235, 103.104607, 94.8427197, 100.855121, 88.7576428, 101.364449,
96.6266614, 99.5170992.
102.955182, 95.5911039, 98.2434651, 97.5397026, 96.5724014, 89.1219276, 111.898084,
95.9322522, 127.127094,
97.0696789, 111.677559, 115.7959, 99.8909647, 96.0591015, 104.014439, 100.031266,
103.058069, 94.4197192,
96.6075493, 117.498147, 101.250734, 98.9487159, 104.350955, 98.7805711, 106.193691,
112.409905, 95.9438902,
112.816701, 95.1258732, 88.468084, 88.0123486, 98.6818012, 91.0403455, 110.278957,
100.027221, 96.1508397,
97.1530639, 98.9738297, 91.611426, 105.313562, 97.4592876, 96.2892631, 96.0740922,
99.1436211, 95.4619736,
93.8951302, 118.116666, 99.8918478, 96.3254983, 95.1235319, 97.3524704, 93.4531296,
103.061139, 90.8262707,
92.9219604, 106.882015, 105.576538, 93.2358826, 97.8484546, 95.0468339, 105.33042,
114.024807, 119.162585,
  112.241221, 98.9774588, 101.014246, 105.505117, 103.154432, 93.807247, 95.0053986,
98.0101888, 96.996672,
100.942181, 107.638163, 103.571802, 94.1691177, 96.3625315, 96.9379715, 99.2542507,
```

```
104.658947, 95.1435321,
103.014793, 96.0287722, 96.3143591, 106.666761, 100.802098, 89.8731728, 105.094329,
99.4435248, 94.7566168,
93.2437362, 110.400254, 116.668369, 102.650094, 103.183044, 103.963022, 95.0016603,
95.415381, 92.6156291,
97.0200954, 106.028275, 103.075164, 99.6682325, 103.251199, 92.1627171, 105.522922,
98.2973017, 95.0638845,
101.23238, 105.420952, 94.3469718, 97.9953125, 93.867685, 93.301505, 101.013913,
98.876758, 102.972457,
110.120956, 93.9075711, 95.8539553, 105.023262, 103.332831, 112.496414, 97.0934702,
96.3381935, 95.2139932,
101.561435,\ 108.071684,\ 98.9923231,\ 104.289514,\ 101.090093,\ 92.483819,\ 99.3598283,
106.940275, 107.123329,
102.449745,\ 101.603933,\ 95.799683,\ 88.1709798,\ 106.453144,\ 91.5031118,\ 93.7045037,\ 106.975997,\ 92.0742743,
94.8728431, 93.8317202, 106.904949, 103.550073, 101.429151, 100.366948, 103.090875,
105.74492, 91.5759535,
99.9182265, \ 99.9311178, \ 102.6302, \ 96.6050429, \ 99.898312, \ 98.2269621, \ 103.833722, \\ 104.155406, \ 104.956193,
  92.0702004, 102.010799, 104.745771, 99.4175256, 94.9556487
])
# 确保数据长度一致
min_len = min(len(bmi_data), len(predicted_times))
df = pd.DataFrame({
  'bmi': bmi_data[:min_len],
  'predicted_time': predicted_times[:min_len]
})
#设置matplotlib以正确显示中文
plt.rcParams['font.sans-serif'] = ['SimHei', 'Arial Unicode MS']
plt.rcParams['axes.unicode_minus'] = False
# --- 2. 分组与风险函数定义 ---
def assign_bmi_group(bmi):
  """根据您提供的K-Means结果边界,为BMI分配组别"""
  if bmi < 29.95:
    return '低BMI组 (<29.95)'
  elif 29.95 <= bmi < 31.62:
    return '中BMI组 (29.95-31.62)'
  elif 31.62 <= bmi < 33.44:
    return '中高BMI组 (31.62-33.44)'
  else: # bmi >= 33.44
    return '高BMI组 (>33.44)'
# 将分组信息添加到DataFrame中
df['bmi_group'] = df['bmi'].apply(assign_bmi_group)
def calculate_group_risk(x, group_predicted_times):
  计算单个组在给定检测时间x下的总风险。
  使用新的风险函数: 100*(x-84)/105 * 总人数 + 未达标人数 * 3
  group_size = len(group_predicted_times)
  if group\_size == 0:
    return 0
  # 未达标人数: 预测时间 > 设定的检测时间x
  not_meeting_standard_count = np.sum(group_predicted_times > x)
```

```
# 总风险 = 100*(x-84)/105 * 总人数 + 未达标人数 * 3
  total_risk = 100 ** ( (x - 84) / 105 ) * group_size + not_meeting_standard_count * 3
  return total risk
# --- 3. 分析与可视化 ---
def analyze_and_plot_groups(dataframe):
    "对每个组进行风险分析并绘制曲线"
  plt.figure(figsize=(15, 10))
  # 为每个组定义一个颜色以便区分
  colors = {
    低BMI组 (<29.95)': 'green',
    '中BMI组 (29.95-31.62)': 'blue',
    '中高BMI组 (31.62-33.44)': 'orange',
    '高BMI组 (>33.44)': 'red'
  #按顺序获取组名,确保图例顺序一致
  group_names = ['低BMI组 (<29.95)', '中BMI组 (29.95-31.62)', '中高BMI组 (31.62-33.44)', '
高BMI组 (>33.44)']
  print("--- 各BMI分组风险分析 (基于新风险函数: 100*(x-84)/105*总人数 + 未达标人数*3)
  for name in group_names:
    group_df = dataframe[dataframe['bmi_group'] == name]
    group_times = group_df['predicted_time'].values
    group_size = len(group_times)
    if group_size == 0:
      print(f"\n组名: {name} - 该组没有样本,已跳过。")
    # 设定一个覆盖该组所有预测时间的范围进行分析
    time_range = np.linspace(min(group_times) - 5, max(group_times) + 5, 1000)
    # 计算该组在整个时间范围内的风险值
    risks_over_time = [calculate_group_risk(x, group_times) for x in time_range]
    # 找到风险最小的点
    min_risk_value = np.min(risks_over_time)
    # 找到风险值首次达到最小值的那个时刻x
    optimal x index = np.argmin(risks over time)
    optimal_x = time_range[optimal_x_index]
    # --- 打印该组的结果 ---
    print(f"\n组名: {name}")
    print(f" - 样本数: {group_size}")
    print(f" - 预测时间范围: [{np.min(group_times):.2f}, {np.max(group_times):.2f}]")
    print(f" => 最佳检测时间 (x): {optimal_x:.2f} 天") print(f" => 对应最小风险值: {min_risk_value:.2f}")
    # --- 绘制曲线 ---
    color = colors.get(name)
    plt.plot(time_range, risks_over_time,
         label=f"{name} (N={group_size})",
         color=color, linewidth=2.5)
    # 标记最佳点
```

```
plt.scatter(optimal_x, min_risk_value,
           color=color, s=200, marker='*', zorder=5,
           edgecolor='black', linewidth=1,
           label=f'{name} 最佳点')
  plt.title('各BMI分组的队列风险与最佳检测时间\n(风险函数: 100*(x-84)/105*总人数 + 未
达标人数*3)', fontsize=16, weight='bold')
  plt.xlabel('设定的检测时间 x (天)', fontsize=14)
  plt.ylabel('队列总风险', fontsize=14)
  plt.legend(fontsize=12, loc='upper right')
  plt.grid(True, which='both', linestyle='--', linewidth=0.5)
  plt.tight_layout()
  plt.show()
# --- 4. 主程序执行 ---
if __name__ == "__main__":
  analyze_and_plot_groups(df)
  print("\n--- 分析说明 ---")
  print("1. **风险模型**: 本次分析使用新的风险函数 `总风险 = 100**(x-84)/105*总人数 +
未达标入数*3`。")
print("2. **曲线特征**: 新的风险函数不再是单调的,而是呈现U型曲线。第一部分随着x增加而线性增加,第二部分随着x增加而减少。")
print("3. ***最佳时间**: 图中的星号(*)标出了风险达到最小值的时刻,这是第一部分和
第二部分权衡的结果。")
                          现在要把数据改成给出表格中的,那么代码应该怎么写
    回复4:我将修改代码,从提供的Excel文件内容中读取BMI和预测时间数据,而不是使
用硬编码的数组。以下是完整的修改后代码:
    "python
    import numpy as np
    import pandas as pd
    import matplotlib.pyplot as plt
    from io import StringIO
    # --- 1. 从提供的文件内容中提取数据 ---
    # 解析文件内容
    file_content = """[file content from your question]""" # 这里应该是你提供的完整文件
内容
    #提取个体预测结果表格
    individual_data = []
    lines = file_content.split('\n')
    start_individual = False
    for line in lines:
      if '> metadata.sheet_name: 个体预测结果' in line:
        start_individual = True
        continue
      if start_individual and line.startswith('> metadata.sheet_name:'):
      if start_individual and '|' in line and not line.startswith('|:') and not line.startswith('| A'):
        #解析数据行
        parts = line.split('|')
        if len(parts) >= 7: # 确保有足够的列
           bmi = parts[5].strip()
           predicted_time = parts[6].strip()
           # 只处理有效数据
           if bmi and predicted_time and bmi != 'BMI' and predicted_time != '预测达到时
间':
             try:
```

```
individual_data.append({
             'bmi': float(bmi),
             'predicted_time': float(predicted_time)
           })
         except ValueError:
           continue
# 创建DataFrame
df = pd.DataFrame(individual_data)
# 设置matplotlib以正确显示中文
plt.rcParams['font.sans-serif'] = ['SimHei', 'Arial Unicode MS']
plt.rcParams['axes.unicode_minus'] = False
# --- 2. 分组与风险函数定义 ---
def assign_bmi_group(bmi):
    """根据您提供的K-Means结果边界,为BMI分配组别"""
  if bmi < 29.95:
    return '低BMI组 (<29.95)'
  elif 29.95 <= bmi < 31.62:
    return '中BMI组 (29.95-31.62)'
  elif 31.62 <= bmi < 33.44:
    return '中高BMI组 (31.62-33.44)'
  else: # bmi >= 33.44
    return '高BMI组 (>33.44)'
# 将分组信息添加到DataFrame中
df['bmi_group'] = df['bmi'].apply(assign_bmi_group)
def calculate_group_risk(x, group_predicted_times):
  计算单个组在给定检测时间x下的总风险。
  使用新的风险函数: 100*(x-84)/105 * 总人数 + 未达标人数 * 3
  group_size = len(group_predicted_times)
  if group size == 0:
    return 0
  # 未达标人数: 预测时间 > 设定的检测时间x
  not_meeting_standard_count = np.sum(group_predicted_times > x)
  # 总风险 = 100*(x-84)/105 * 总人数 + 未达标人数 * 3
  total_risk = 100 ** ((x - 84) / 105) * group_size + not_meeting_standard_count * 3
  return total risk
# --- 3. 分析与可视化 ---
def analyze_and_plot_groups(dataframe):
    "对每个组进行风险分析并绘制曲线"
  plt.figure(figsize=(15, 10))
  # 为每个组定义一个颜色以便区分
  colors = {
     低BMI组 (<29.95)': 'green',
    '中BMI组 (29.95-31.62)': 'blue',
    '中高BMI组 (31.62-33.44)': 'orange',
    '高BMI组 (>33.44)': 'red'
  }
  #按顺序获取组名,确保图例顺序一致
  group_names = ['低BMI组 (<29.95)', '中BMI组 (29.95-31.62)', '中高BMI组 (31.62-
```

```
print("--- 各BMI分组风险分析 (基于新风险函数: 100*(x-84)/105*总人数 + 未达标人
数*3) ---")
      for name in group names:
        group_df = dataframe[dataframe['bmi_group'] == name]
       group times = group df['predicted time'].values
        group_size = len(group_times)
       if group_size == 0:
          continue
       # 设定一个覆盖该组所有预测时间的范围进行分析
       time range = np.linspace(min(group times) - 5, max(group times) + 5, 1000)
        # 计算该组在整个时间范围内的风险值
       risks_over_time = [calculate_group_risk(x, group_times) for x in time_range]
       # 找到风险最小的点
       min_risk_value = np.min(risks_over_time)
        # 找到风险值首次达到最小值的那个时刻x
       optimal_x_index = np.argmin(risks_over_time)
       optimal_x = time_range[optimal_x_index]
       # --- 打印该组的结果 ---
       print(f"\n组名: {name}")
        print(f" - 样本数: {group_size}")
        print(f" - 预测时间范围: [{np.min(group_times):.2f}, {np.max(group_times):.2f}]")
       print(f" => 最佳检测时间(x): {optimal_x:.2f} 天")
       print(f" => 对应最小风险值: {min_risk_value:.2f}")
        # --- 绘制曲线 ---
       color = colors.get(name)
        plt.plot(time_range, risks_over_time,
            label=f"{name} (N={group size})",
            color=color, linewidth=2.5)
       # 标记最佳点
        plt.scatter(optimal_x, min_risk_value,
              color=color, s=200, marker='*', zorder=5,
              edgecolor='black', linewidth=1,
              label=f'{name} 最佳点')
      plt.title('各BMI分组的队列风险与最佳检测时间\n(风险函数: 100*(x-84)/105*总人数
+ 未达标人数*3)', fontsize=16, weight='bold')
      plt.xlabel('设定的检测时间 x (天)', fontsize=14)
      plt.ylabel('队列总风险', fontsize=14)
      plt.legend(fontsize=12, loc='upper right')
      plt.grid(True, which='both', linestyle='--', linewidth=0.5)
      plt.tight_layout()
     plt.show()
    # --- 4. 主程序执行 ---
   if __name__ == "__main__":
analyze_and_plot_groups(df)
print("2. **曲线特征**: 新的风险函数不再是单调的,而是呈现U型曲线。第一部分
随着x增加而线性增加,第二部分随着x增加而减少。")
```

print("3. **最佳时间**: 图中的星号(*)标出了风险达到最小值的时刻,这是第一部分 和第二部分权衡的结果。

注意:由于你提供的文件内容非常长,我无法在这里完整粘贴。你需要将完整的文件 内容替换到代码中的`file_content`变量中。代码会解析这个内容,提取BMI和预测时间数据 ,然后进行分析。

这个代码会:

- 1. 从你提供的文件内容中解析出BMI和预测时间数据
- 2. 根据BMI值将样本分成4个组
- 3. 对每个组计算在不同检测时间x下的风险值
- 4. 绘制风险曲线并标记最佳检测时间点
- 5. 输出每个组的最佳检测时间和最小风险值

如果你需要直接读取Excel文件而不是解析文本内容,我可以提供另一种实现方式。

提示词5: SPSSPRO中的"交叉分析"是否可以完成交叉验证评估 回复5: 您好! 这是一个非常常见且重要的概念混淆问题。

直接的回答是: **不可以**。

SPSSPRO中的"交叉分析"功能**无法**完成机器学习中的"交叉验证"评估。这两个术语 虽然名字相似,但完全是两回事,用于完全不同的目的。

下面我为您详细解释一下:

1. SPSSPRO中的"交叉分析"(Cross-Tabulation)

- * **本质**: 一种**统计描述**方法,用于分析两个或多个**分类变量**之间的关系。 * **功能**: 它会产生一个列联表(Contingency Table),展示变量不同类别组合下 的频数、百分比(行百分比、列百分比、总百分比)。 * **目的**:
- * 查看数据的分布情况。例如,不同性别(男/女)的人群在购买决策(买/不买) 上的分布。
- * 进行卡方检验(Chi-Square Test),判断两个分类变量之间是否存在显著的关联
 - * **输出结果**: 一个表格, 通常附带卡方检验的p值, 用于判断显著性。
 - * **举例**: 分析"性别"和"是否喜欢某产品"的关系。

```
| 喜欢 | 不喜欢 | 总计 | |
|---|---|---|---|
| **男** | 30 | 20 | 50 |
|**女** |40 |10 |50 |
|**总计**|70 |30 |100 |
```

然后进行卡方检验,看性别和偏好之间是否有显著关系。

2. 交叉验证(Cross-Validation)

- * **本质**:一种**模型评估**方法,主要用于机器学习和预测建模。 * **功能**:将数据集巧妙地分成"训练集"和"测试集",多次循环训练和测试模型,以 得到一个更稳定、更可靠的模型性能评估指标(如准确率、精确率、AUC等)。
 - * **目的**:
- * **评估模型泛化能力**: 防止模型因为过度依赖训练数据(过拟合)而在新数据 上表现不佳。
- * **比较不同模型**: 为同一个问题尝试多种算法(如逻辑回归、决策树、随机森 林),用交叉验证的结果选择表现最好的模型。
 - * **调整模型参数**:与网格搜索(Grid Search)结合,寻找最优的模型参数。

- * **常见类型**: K折交叉验证(K-Fold CV)、留一法交叉验证(Leave-One-Out CV)等。
 - 。 * **举例(5折交叉验证)**:
 - 1. 将数据随机分成5等份。
 - 2. 每次用其中4份数据训练模型,用剩下的1份数据测试模型,并记录性能得分。
 - 3. 重复5次,确保每一份数据都恰好被作为测试集一次。
 - 4. 最终计算5次得分的平均值,作为模型性能的最终评估。

总结与对比

| 特性 | **交叉分析 (SPSSPRO)** | **交叉验证 (Cross-Validation)** | |:--- |:--- |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |:--- | |

| **本质** | **统计检验方法** | **模型评估策略** |

那么在SPSSPRO中,如何完成"交叉验证"呢?

虽然"交叉分析"不能做,但SPSSPRO在其他模块提供了交叉验证的功能。**路径通常是在机器学习或预测建模相关的模块中**。

例如,在**【机器学习】->【分类】或【回归】** 等板块中,当您选择了一个算法(如逻辑回归、决策树)后,在参数设置或高级选项里,通常会有 **【验证方法】** 的选择。

- 1. 您会看到诸如 **"训练集-测试集划分"**、**"K折交叉验证"** 等选项。
- 2. 选择"K折交叉验证"并设置折数(如5或10),SPSSPRO便会自动执行上述的交叉验证流程,并最终给出一个基于交叉验证的模型评估报告。

**结论: **

请不要使用"交叉分析"功能来评估模型性能。如果您需要进行交叉验证,请前往SPSSPRO的**机器学习建模模块**,并在相应的算法配置中找到验证方法设置。

提示词6:python如何调用库画散点图回复6:# 使用Python绘制散点图

Python中主要使用matplotlib和seaborn这两个库来绘制散点图。以下是详细的步骤和示例代码:

使用matplotlib绘制散点图

"python import matplotlib.pyplot as plt import numpy as np

创建示例数据

np.random.seed(42) # 确保结果可重现 x = np.random.rand(50) # 50个随机x值 y = np.random.rand(50) # 50个随机y值 colors = np.random.rand(50) # 为每个点随机颜色 sizes = 100 * np.random.rand(50) # 为每个点随机大小

创建散点图

plt.figure(figsize=(8, 6)) # 设置图形大小 scatter = plt.scatter(x, y, c=colors, s=sizes, alpha=0.7, cmap='viridis')

#添加标题和轴标签

```
plt.title('示例散点图')
plt.xlabel('X轴')
plt.ylabel('Y轴')
#添加颜色条
plt.colorbar(scatter, label='颜色值')
#显示图形
plt.show()
## 使用seaborn绘制散点图
"python
import seaborn as sns
import pandas as pd
import numpy as np
# 创建示例数据框
np.random.seed(42)
data = pd.DataFrame({
  'x': np.random.randn(100),
  'y': np.random.randn(100),
  'category': np.random.choice(['A', 'B', 'C'], 100),
  'size': np.random.uniform(10, 100, 100)
})
# 创建散点图
plt.figure(figsize=(8, 6))
sns.scatterplot(
  data=data,
  x='x',
  y='y',
  hue='category', # 按类别着色
size='size', # 按大小区分
sizes=(20, 200), # 大小范围
  alpha=0.7
#添加标题
plt.title('Seaborn散点图示例')
#显示图形
plt.show()
## 进阶示例: 使用实际数据集
```python
import seaborn as sns
import matplotlib.pyplot as plt
加载内置数据集
tips = sns.load_dataset("tips")
创建散点图
plt.figure(figsize=(10, 6))
sns.scatterplot(
 data=tips,
 x='total_bill',
 y='tip',
 hue='time',
 #按午餐/晚餐着色
 size='size', #按聚餐人数设置点的大小
```

```
style='smoker', # 按是否吸烟者设置点的样式
 sizes=(30, 200),
 alpha=0.8
#添加标题和轴标签
plt.title('小费与总账单金额关系')
plt.xlabel('总账单金额 ($)')
plt.ylabel('小费金额 ($)')
#添加图例
plt.legend(bbox_to_anchor=(1.05, 1), loc='upper left')
调整布局
plt.tight_layout()
#显示图形
plt.show()
安装必要的库
如果你还没有安装这些库,可以使用以下命令安装:
```bash
pip install matplotlib seaborn pandas numpy
```

这些示例展示了如何使用Python绘制基本的和高级的散点图。你可以根据自己的数据和需求调整参数,如颜色、大小、透明度等,以创建最适合你数据的可视化效果。

4. 采纳和人工修改情况

对于以上的AI交互,我们认真分析并理解了AI生成的内容,并根据自己的理解应用在代码编写和模型建立的过程中。对于AI给出的名词解释,我们理解后用自己的语言写在论文中;对于数据处理,我们直接用于建立模型,但只是作为小范围数据提取工具使用;对于代码编写,我们学习了一些AI给出的算法或思路自行进行了代码编写。